## Выгрузка данных из лабораторной работы №2 (вариант №11)

## Вариант №11: [misc.forsale, sci.med, talk.religion.misc]

```
In [1]: import warnings
        from sklearn.datasets import fetch_20newsgroups
        warnings.simplefilter(action='ignore', category=FutureWarning)
In [2]: categories = ['misc.forsale', 'sci.med', 'talk.religion.misc']
        remove = ['headers', 'footers', 'quotes']
        twenty_train_full = fetch_20newsgroups(subset='train', categories=categories, sh
        twenty_test_full = fetch_20newsgroups(subset='test', categories=categories, shuf
        Применение стемминга
In [3]:
        import nltk
        from nltk import word_tokenize
        from nltk.stem import *
        nltk.download('punkt')
```

```
[nltk_data] Downloading package punkt to
        [nltk_data] C:\Users\Vitaly\AppData\Roaming\nltk_data...
        [nltk_data] Package punkt is already up-to-date!
Out[3]: True
```

```
In [4]: def stemming(data):
            porter_stemmer = PorterStemmer()
            stem = []
            for text in data:
                nltk_tokens = word_tokenize(text)
                line = ''.join([' ' + porter_stemmer.stem(word) for word in nltk_tokens]
                stem.append(line)
            return stem
```

```
In [5]: stem_train = stemming(twenty_train_full.data)
        stem_test = stemming(twenty_test_full.data)
```

## Вариант №11

### Методы: [MNB, DT, KNN]

```
In [6]: from sklearn.naive_bayes import MultinomialNB
        from sklearn.tree import DecisionTreeClassifier
```

```
from sklearn.neighbors import KNeighborsClassifier
In [7]: stop_words = [None, 'english']
         max_features_values = [100, 500, 1000, 2000, 3000, 4000, 5000]
         use_idf = [True, False]
In [8]: dt_first = range(1, 5, 1)
         dt_{second} = range(5, 100, 20)
         decision_tree_max_depth = [*dt_first, *dt_second]
In [9]: parameters_mnb = {
             'vect__max_features': max_features_values,
              'vect__stop_words': stop_words,
             'tfidf__use_idf': use_idf,
             'clf__alpha': (0.1, 1, 2)
         parameters_dtc = {
             'vect__max_features': max_features_values,
              'vect__stop_words': stop_words,
             'tfidf__use_idf': use_idf,
             'clf__criterion': ('gini', 'entropy'),
             'clf__max_depth': decision_tree_max_depth,
         }
         parameters_knc = {
             'vect__max_features': max_features_values,
             'vect__stop_words': stop_words,
             'tfidf__use_idf': use_idf,
             'clf__n_neighbors': range(1, 10),
             'clf__p': (2, 1) # 2 - Евклидово, 1 - городские кварталы
        from sklearn.model_selection import GridSearchCV
In [10]:
         from sklearn.pipeline import Pipeline
         from sklearn.feature_extraction.text import CountVectorizer, TfidfTransformer
```

# Наивный байесовский классификатор

#### Без использования стема

#### С использованием стема

# Дерево решений

#### Без использования стема

#### С использованием стема

# К-ближайших соседей

#### Без использования стема

## С использованием стема

stop\_words': 'english'}

# Вывод полученных результатов анализа

```
In [17]: from sklearn.metrics import classification report
In [18]: predicted_mnb = gscv_mnb.predict(twenty_test_full.data)
        print('Наивный байесовский классификатор без стема\n')
        print(classification_report(twenty_test_full.target, predicted_mnb, target_names
        print(gscv_mnb.best_params_)
        Наивный байесовский классификатор без стема
                           precision recall f1-score support
              misc.forsale 0.95
                                       0.94
                                                 0.95
                                                             390
                   sci.med
                              0.87
                                        0.92
                                                 0.89
                                                             396
                              0.88
        talk.religion.misc
                                         0.81
                                                  0.84
                                                             251
                                                  0.90
                                                            1037
                  accuracy
                 macro avg 0.90 0.89
ighted avg 0.90 0.90
                                                 0.90
                                                            1037
              weighted avg
                                                  0.90
                                                            1037
        {'clf alpha': 0.1, 'tfidf use idf': True, 'vect max features': 5000, 'vect
        stop_words': 'english'}
In [19]:
        predicted_mnb_stem = gscv_mnb_stem.predict(twenty_test_full.data)
        print('Наивный байесовский классификатор со стемом\n')
        print(classification_report(twenty_test_full.target, predicted_mnb_stem, target_
        print(gscv_mnb_stem.best_params_)
        Наивный байесовский классификатор со стемом
                           precision recall f1-score support
              misc.forsale
                              0.89
                                         0.94
                                                  0.92
                                                             390
                              0.87
0.86
        sci.med
talk.religion.misc
                                         0.86
                                                  0.86
                                                             396
                                         0.80
                                                  0.83
                                                             251
                                                  0.88
0.87
                  accuracy
                                                            1037
                              0.87 0.87 0.87
                 macro avg
                                                            1037
              weighted avg
                              0.87
                                         0.88
                                                 0.87
                                                          1037
         {'clf_alpha': 0.1, 'tfidf_use_idf': True, 'vect_max_features': 5000, 'vect_
```

```
In [20]: predicted_dt = gscv_dt.predict(twenty_test_full.data)
        print('Дерево решений без стема\n')
        print(classification_report(twenty_test_full.target, predicted_dt, target_names=
        print(gscv_dt.best_params_)
        Дерево решений без стема
                           precision recall f1-score support
              misc.forsale
                              0.83
                                       0.84
                                                 0.84
                                                            390
                   sci.med
                              0.79
                                        0.57
                                                  0.66
                                                            396
        talk.religion.misc
                              0.54
                                         0.77
                                                 0.64
                                                            251
                                                  0.72
                                                           1037
                 accuracy
                 macro avg
                              0.72
                                         0.73
                                                  0.71
                                                           1037
              weighted avg
                               0.75
                                         0.72
                                                  0.72
                                                           1037
        {'clf__criterion': 'gini', 'clf__max_depth': 65, 'tfidf__use_idf': True, 'vect_
        _max_features': 1000, 'vect__stop_words': 'english'}
In [21]: predicted_dt_stem = gscv_dt_stem.predict(twenty_test_full.data)
        print('Дерево решений со стемом\n')
        print(classification_report(twenty_test_full.target, predicted_dt_stem, target_r
        print(gscv dt stem.best params )
        Дерево решений со стемом
                           precision recall f1-score support
              misc.forsale
                              0.80
                                         0.72
                                                  0.76
                                                            390
                              0.73
                                        0.45
                                                  0.56
                                                            396
                   sci.med
                              0.44
                                         0.78
        talk.religion.misc
                                                  0.57
                                                            251
                                                           1037
                 accuracy
                                                  0.63
                              0.66
                                         0.65
                                                  0.63
                                                           1037
                 macro avg
                              0.69
                                                  0.64
              weighted avg
                                         0.63
                                                            1037
        {'clf criterion': 'gini', 'clf max depth': 65, 'tfidf use idf': False, 'vect
        __max_features': 2000, 'vect__stop_words': 'english'}
In [22]: predicted_knc = gscv_knc.predict(twenty_test_full.data)
        print('K-ближайших соседей без стема\n')
        print(classification_report(twenty_test_full.target, predicted_knc, target_names
        print(gscv knc.best params )
        К-ближайших соседей без стема
                           precision recall f1-score support
              misc.forsale
                              0.77
                                         0.81
                                                  0.79
                                                            390
                               0.71
                                                            396
                   sci.med
                                         0.61
                                                  0.66
        talk.religion.misc
                              0.53
                                         0.61
                                                  0.57
                                                            251
                  accuracy
                                                  0.69
                                                           1037
                                                0.67
                              0.67
                                         0.68
                                                           1037
```

{'clf\_\_n\_neighbors': 4, 'clf\_\_p': 2, 'tfidf\_\_use\_idf': True, 'vect\_\_max\_feature
s': 100, 'vect\_\_stop\_words': 'english'}

0.69

1037

0.69

0.69

macro avg weighted avg

```
In [23]: predicted knc stem = gscv knc stem.predict(twenty test full.data)
        print('K-ближайших соседей со стемом\n')
        print(classification_report(twenty_test_full.target, predicted_knc_stem, target_
        print(gscv_knc_stem.best_params_)
        К-ближайших соседей со стемом
                           precision recall f1-score support
              misc.forsale
                              0.62
                                        0.80
                                                 0.70
                                                             390
                   sci.med
                               0.58
                                        0.61
                                                  0.59
                                                             396
        talk.religion.misc
                              0.71
                                         0.33
                                                  0.45
                                                             251
                                                   0.61
                                                            1037
                  accuracy
                 macro avg
                              0.64
                                         0.58
                                                   0.58
                                                            1037
              weighted avg
                                0.63
                                         0.61
                                                   0.60
                                                            1037
        {'clf__n_neighbors': 2, 'clf__p': 2, 'tfidf__use_idf': True, 'vect__max_feature
        s': 100, 'vect__stop_words': 'english'}
```

## Сравнительная таблица

```
In [24]: import pandas as pd
In [25]: writer = pd.ExcelWriter('result.xlsx', engine='openpyxl')
         # Наивный байесовский классификатор без стема
         df1 = pd.DataFrame(classification_report(predicted_mnb, twenty_test_full.target,
         # Наивный байесовский классификатор со стемом
         df2 = pd.DataFrame(classification_report(predicted_mnb_stem, twenty_test_full.ta
         # Дерево решений без стема
         df3 = pd.DataFrame(classification_report(predicted_dt, twenty_test_full.target,
         # Дерево решений со стемом
         df4 = pd.DataFrame(classification_report(predicted_dt_stem, twenty_test_full.tar
         # К-ближайших соседей без стема
         df5 = pd.DataFrame(classification report(predicted knc, twenty test full.target,
         # К-ближайших соседей со стемом
         df6 = pd.DataFrame(classification_report(predicted_knc_stem, twenty_test_full.ta
         df1.to_excel(writer, sheet_name='HBK без стема')
         df2.to_excel(writer, sheet_name='HBK co ctemom')
         df3.to excel(writer, sheet name='Дерево решений без стема')
         df4.to_excel(writer, sheet_name='Дерево решений со стемом')
         df5.to_excel(writer, sheet_name='K-ближайших соседей без стема')
         df6.to_excel(writer, sheet_name='K-ближайших соседей со стемом')
         writer.save()
In [26]: |gscv_mnb.best_params_
Out[26]: {'clf_alpha': 0.1,
           'tfidf__use_idf': True,
           'vect__max_features': 5000,
           'vect__stop_words': 'english'}
In [26]:
```